

LAPORAN TRAINING

IMPORTANCE FITUR - SURVIVAL PREDICTION

Kanker Kolorektal | SMOTE K=5 | 4 Algoritma ML

Analisis fitur importance untuk memprediksi Survival_Prediction menggunakan 4 algoritma machine learning dengan SMOTE oversampling

Target	Survival_Prediction (Yes/No)
Total Dataset	167,497 baris
Sample	30,000 baris (stratified)
Fitur Awal	46 fitur (setelah One-Hot Encoding)
Fitur Terpilih	10 fitur (intersection RF + MI)
SMOTE	K=5 (balancing classes)
Train/Test Split	80/20
Setelah SMOTE	28,782 baris (50:50 ratio)
Algoritma	SVM, XGBoost, Random Forest, KNN, Baseline

1. FEATURE IMPORTANCE ANALYSIS

Feature Importance dihitung menggunakan dua metode untuk menentukan fitur yang paling berpengaruh terhadap target **Survival_Prediction**.

1.1 Random Forest Feature Importance (Top 15)

Random Forest mengukur seberapa sering suatu fitur digunakan untuk split di seluruh decision tree. Semakin tinggi nilai, semakin penting fitur tersebut.


No	Fitur	Importance	%
1	Healthcare_Costs	0.1307	13.07%
2	Tumor_Size_mm	0.0997	9.97%
3	Incidence_Rate_per_100K	0.0942	9.42%
4	Age	0.0927	9.27%
5	Mortality_Rate_per_100K	0.0819	8.19%
6	Gender_M	0.0174	1.74%
7	Family_History_Yes	0.0172	1.72%
8	Economic_Classification_Developing	0.0171	1.71%
9	Urban_or_Rural_Urban	0.0170	1.70%
10	Smoking_History_Yes	0.0167	1.67%
11	Insurance_Status_Uninsured	0.0167	1.67%
12	Healthcare_Access_Moderate	0.0165	1.65%
13	Alcohol_Consumption_Yes	0.0164	1.64%
14	Screening_History_Regular	0.0163	1.63%
15	Obesity_BMI_Overweight	0.0162	1.62%

1.2 Mutual Information Score (Top 15)

Mutual Information mengukur ketergantungan antara fitur dan target. Nilai 0 berarti independen (tidak ada informasi bersama).

No	Fitur	MI Score
1	Screening_History_Never	0.0070
2	Early_Detection_Yes	0.0062
3	Insurance_Status_Uninsured	0.0055
4	Obesity_BMI_Overweight	0.0055
5	Screening_History_Regular	0.0046
6	Gender_M	0.0045
7	Inflammatory_Bowel_Disease_Yes	0.0043

8	Country_Germany	0.0040
9	Treatment_Type_Surgery	0.0038
10	Obesity_BMI_Obese	0.0030
11	Family_History_Yes	0.0025
12	Genetic_Mutation_Yes	0.0024
13	Economic_Classification_Developing	0.0024
14	Country_South Africa	0.0019
15	Cancer_Stage_Regional	0.0018



Gambar 1: Perbandingan Feature Importance (RF vs Mutual Information)

2. SELEKSI FITUR TERPILIH

Fitur dipilih berdasarkan **intersection** dari Top 20 RF Importance dan Top 20 Mutual Information. Hasilnya adalah 10 fitur yang konsisten penting di kedua metode pengukuran.

No	Fitur	Kategori	Keterangan
1	Alcohol_Consumption_Yes	Kategorikal (encoded)	Riwayat konsumsi alkohol / Lifestyle
2	Cancer_Stage_Regional	Kategorikal (encoded)	Stadium kanker regional / Klinis
3	Early_Detection_Yes	Kategorikal (encoded)	Deteksi dini / Screening
4	Economic_Classification_Developing	Kategorikal (encoded)	Klasifikasi negara berkembang / Demografi
5	Family_History_Yes	Kategorikal (encoded)	Riwayat keluarga / Genetik
6	Gender_M	Kategorikal (encoded)	Jenis kelamin pria / Demografi
7	Incidence_Rate_per_100K	Numerik	Tingkat insidensi / Epidemiology
8	Insurance_Status_Uninsured	Kategorikal (encoded)	Status tidak punya asuransi / Ekonomi
9	Obesity_BMI_Overweight	Kategorikal (encoded)	Obesitas (overweight) / Lifestyle
10	Screening_History_Regular	Kategorikal (encoded)	Riwayat screening rutin / Screening

Catatan: 5 fitur numerik (Age, Tumor_Size_mm, Healthcare_Costs, Mortality_Rate_per_100K) memiliki RF importance tinggi (~0.08–0.13) namun tidak lolos intersection karena MI Score rendah. Ini menunjukkan hubungan non-linear yang kompleks dengan target.

3. TARGET VARIABLE & IMBALANCE HANDLING

3.1 Target: Survival_Prediction

Target **Survival_Prediction** adalah variabel biner yang menunjukkan prediksi kelangsungan hidup pasien kanker kolorektal:

Kelas	Jumlah	Persentase	Kode
Yes (Hidup)	17,989	60.0%	1
No (Meninggal)	12,011	40.0%	0
Total	30,000	100%	-

3.2 SMOTE Oversampling (K=5)

SMOTE (Synthetic Minority Oversampling Technique) adalah teknik untuk menangani data tidak seimbang dengan membuat sampel sintetis dari kelas minoritas. Parameter K=5 berarti menggunakan 5 tetangga terdekat untuk menginterpolasi sampel baru.

Tahap	Yes (Hidup)	No (Meninggal)	Total	Ratio
Sebelum SMOTE	14,391	9,609	24,000	60:40
Setelah SMOTE (K=5)	14,391	14,391	28,782	50:50

Keuntungan SMOTE: Menyeimbangkan kelas tanpa kehilangan data, mengurangi bias model terhadap kelas mayoritas, dan menghasilkan sampel sintetis yang realistis.

4. TRAINING 4 ALGORITMA MACHINE LEARNING

Empat algoritma klasifikasi dilatih menggunakan fitur terpilih dengan SMOTE K=5. SVM dan KNN menggunakan data terstandarisasi (StandardScaler), sementara XGBoost dan Random Forest menggunakan data mentah (tree-based tidak sensitif skala).

SVM (Support Vector Machine)

Mencari hyperplane terbaik yang memisahkan kelas. Menggunakan LinearSVC dengan `class_weight='balanced'` dan CalibratedClassifierCV untuk probabilitas.

XGBoost (Extreme Gradient Boosting)

Algoritma boosting berbasis tree yang sangat efisien. Menggunakan 100 estimator, `max_depth=6`, `learning_rate=0.1`.

Random Forest

Ensemble dari 50 decision tree dengan `max_depth=8`. Menggunakan bootstrap aggregation untuk mengurangi overfitting.

KNN (K-Nearest Neighbors)

Klasifikasi berdasarkan jarak ke K=5 tetangga terdekat. Menggunakan `weights='distance'` untuk memberikan bobot lebih pada tetangga terdekat.

5. HASIL PERBANDINGAN KINERJA

5.1 Metrik Evaluasi

Model dievaluasi menggunakan 5 metrik utama pada data test (6,000 sampel):

- **Accuracy:** Proporsi prediksi benar dari total prediksi.
- **Precision:** Proporsi prediksi positif yang benar-benar positif.
- **Recall:** Proporsi data positif yang berhasil diprediksi positif.
- **F1-Score:** Harmonic mean dari Precision dan Recall.
- **ROC-AUC:** Area Under ROC Curve - kemampuan model membedakan kelas.

5.2 Perbandingan Kinerja Model


Rank	Algoritma	Accuracy	Precision	Recall	F1-Score	ROC-AUC	Time
1	XGBoost	0.5160	0.6061	0.5509	0.5772	0.5086	2.15s
2	Random Forest	0.5083	0.6064	0.5133	0.5560	0.5086	0.76s
3	SVM	0.4973	0.5938	0.5122	0.5500	0.4907	6.05s
4	KNN	0.4915	0.5881	0.5072	0.5447	0.4878	0.15s
5	Baseline	0.4003	0.0000	0.0000	0.0000	0.5000	0.02s

■ Model Terbaik: XGBoost dengan ROC-AUC = 0.5086


6. CONFUSION MATRIX

Confusion Matrix menunjukkan perbandingan antara prediksi model dengan nilai aktual untuk setiap algoritma.


SVM



XGBoost




Random_Forest




KNN

KNN - Confusion Matrix
Target: Survival_Prediction + SMOTE K=5




6.1 Semua Confusion Matrix (1 Gambar)



7. ROC CURVES

ROC Curve menggambarkan trade-off antara True Positive Rate dan False Positive Rate. Semakin dekat kurva ke sudut kiri atas, semakin baik performa model.




8. TABEL PERBANDINGAN KINERJA

PERBANDINGAN KINERJA MODEL - Survival_Prediction (SMOTE K=5)

Algoritma	Accuracy	Precision	Recall	F1-Score	ROC-AUC	Time	Rank
XGBoost	0.5160	0.6061	0.5509	0.5772	0.5086	2.15s	1.0
Random Forest	0.5083	0.6064	0.5133	0.5560	0.5086	0.76s	1.7
SVM	0.4973	0.5938	0.5122	0.5500	0.4907	6.05s	3.3
KNN	0.4915	0.5881	0.5072	0.5447	0.4878	0.15s	4.3
Baseline	0.4003	0.0000	0.0000	0.0000	0.5000	0.02s	4.3

8.1 Grafik Perbandingan



9. RINGKASAN CONFUSION MATRIX

Ringkasan nilai True Negative (TN), False Positive (FP), False Negative (FN), dan True Positive (TP) untuk setiap model.

CONFUSION MATRIX SUMMARY - Survival_Prediction (SMOTE K=5)

Model	TN	FP	FN	TP	Accuracy	Precision	Recall	F1-Score
SVM	1,141	1,261	1,755	1,843	0.4973	0.5938	0.5122	0.5500
XGBoost	1,114	1,288	1,616	1,982	0.5160	0.6061	0.5509	0.5772
Random Forest	1,203	1,199	1,751	1,847	0.5083	0.6064	0.5133	0.5560
KNN	1,124	1,278	1,773	1,825	0.4915	0.5881	0.5072	0.5447
Baseline	2,402	0	3,598	0	0.4003	0.0000	0.0000	0.0000

10. KESIMPULAN & REKOMENDASI

10.1 Temuan Utama

- **AUC ~0.5:** Semua model menghasilkan ROC-AUC sekitar 0.5, yang menunjukkan bahwa fitur yang tersedia tidak memiliki sinyal prediktif yang cukup kuat untuk memprediksi Survival_Prediction secara akurat.
- **XGBoost terbaik:** XGBoost menjadi model dengan performa terbaik (ROC-AUC = 0.5086), meskipun masih mendekati prediksi acak.
- **Feature Importance:** Dari 46 fitur awal, hanya 10 fitur yang lolos intersection RF + MI, menunjukkan bahwa sebagian besar fitur memiliki hubungan yang sangat lemah dengan target.
- **SMOTE efektif:** SMOTE K=5 berhasil menyeimbangkan kelas dari rasio 60:40 menjadi 50:50 dengan menambah 4,782 sampel sintetis.

10.2 Rekomendasi

- **Dataset tambahan:** Cari fitur klinis yang lebih relevan seperti TNM staging detail, biomarker (CEA, CA19-9), dan data genetik.
- **Target berbeda:** Survival_5_years mungkin lebih prediktif daripada Survival_Prediction karena memiliki sinyal yang lebih kuat.
- **Deep Learning:** Neural network dengan arsitektur yang lebih kompleks mungkin bisa menangkap pola non-linear yang tidak terdeteksi.
- **Validasi data:** Periksa kembali proses labeling Survival_Prediction karena dataset ini mungkin sintetis (0 missing values + korelasi sangat rendah).

— End of Report —